### 实验目的

编写DPC算法,实现聚类

### 实验原理

DPC算法整合了k-means 算法和 DBSCAN算法,中心思想是:

- 每个聚类的边缘密度较低,中间密度高
- 聚类中心的点通常离其他高密度的点远

所以基于此,采取如下策略:

- 设置距离阈值变量 $d_c$
- 对于每个数据点i, 计算两个值:
  - 。 局部密度:  $ho_i = \sum_j \chi(d_{ij} d_c)$ , 其中  $\chi(x) = 1$  if x < 0 and  $\chi(x) = 0$  if  $x \ge 0$ ;
  - 。 更高密度距离: $\delta_i=\min_{j:\rho_j>\rho_i}d_{ij}$ 。特别的,若当前数据点  $m_i$  为  $\rho$  最大点,则定义  $\delta_i=\max_i d_{ij}$
- 绘制决策图,把 $ho_i$  和 $\delta_i$ 均较大的点设为聚类中心,把 $\delta_i$ 大而 $ho_i$ 小的点设置为OOD点
- 按照密度从高到低排序,把每个点分配给最近的有更高密度的聚类中心的类

### 实验步骤

#### **Load and Process Data**

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
df = {}
df[0] = pd.read_csv('Datasets\Aggregation.txt', header=None, sep=" ")
df[1] = pd.read_csv('Datasets\D31.txt', header=None, sep=" ")
df[2] = pd.read_csv('Datasets\R15.txt', header=None, sep=" ")
```

```
for i in range(3):
    min_val = df[i].min()
    max_val = df[i].max()

    df[i] = (df[i] - min_val) / (max_val - min_val)

array = {}
for i in range(3):
    array[i] = df[i].to_numpy()
```

#### Calculate distance

计算 $\rho_i$  和 $\delta_i$ 都要用到点之间的距离,这里用矩阵乘法来代替循环的计算

```
def _calculate_distance(self, X):
    m, n = X.shape
    X_square = np.square(X)
    ones = np.ones((m, n))
    D_square = X_square @ ones.T + ones @ X_square.T - 2 * X @ X.T
    self.D = np.sqrt(np.abs(D_square))
```

#### Calculate\_delta

按实验原理的公式计算

#### Calculate\_local\_density

按公式计算

```
def _calculate_local_density(self, X):
    m = X.shape[0]
    self.rho = np.zeros(m)

for i in range(m):
    for j in range(m):
        distance = self.D[i][j]
        if distance < self.dc:
            self.rho[i] += 1
    self.rho[i] = self.rho[i] + np.random.rand()/1000</pre>
```

#### **Pridict**

确定聚类中心和OOD点,然后按照密度从高到低排序,把每个点分配给最近的有更高密度的聚类中心的 类

```
def predict(self, X, rho_bound, delta_bound):
    # center
```

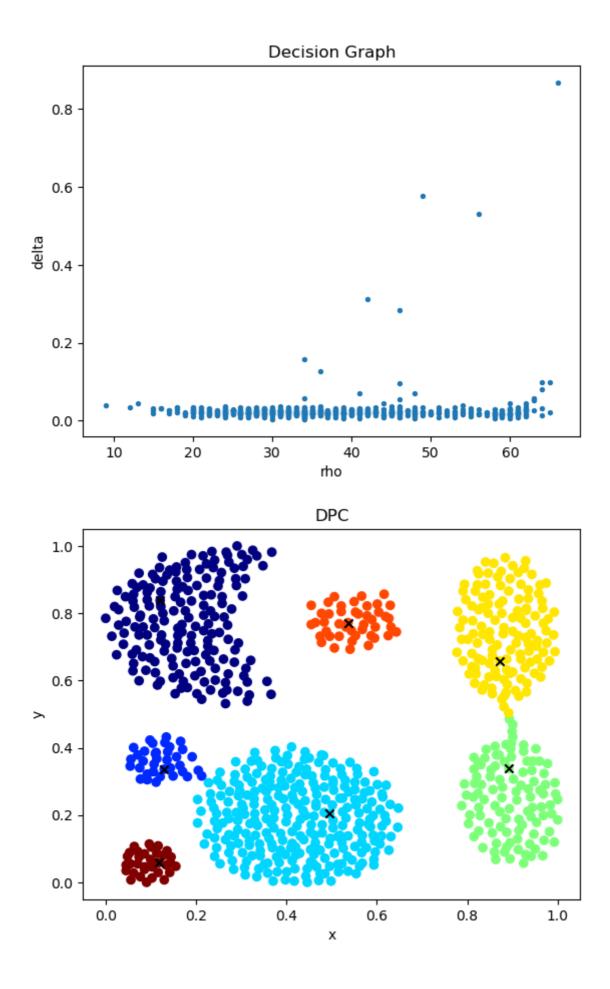
```
self.center = []
        self.outliers = []
        m = X.shape[0]
        for i in range(m):
            if self.rho[i] >= rho_bound and self.delta[i] >= delta_bound:
                self.center.append(i)
            elif self.rho[i] < rho_bound and self.delta[i] >= delta_bound:
                self.outliers.append(i)
        self.labels = np.zeros(m)
        for i in range(len(self.center)):
            self.labels[self.center[i]] = i + 1
        rho_index = np.argsort(-self.rho)
        for i in range(m):
            if (not rho_index[i] in self.outliers) and self.labels[rho_index[i]]
== 0:
                cluster_index = rho_index[np.argmin(self.D[rho_index[i]]
[rho_index[:i]])]
                self.labels[rho_index[i]] = self.labels[cluster_index]
        plt.figure()
        plt.title('DPC')
        plt.xlabel('x')
        plt.ylabel('y')
        plt.scatter(X[:, 0], X[:, 1], c = self.labels, cmap = "jet")
        plt.scatter(X[self.center][:, 0], X[self.center][:, 1], c = 'black',
marker = 'x')
        plt.show()
        return self.labels
```

# 实验结果

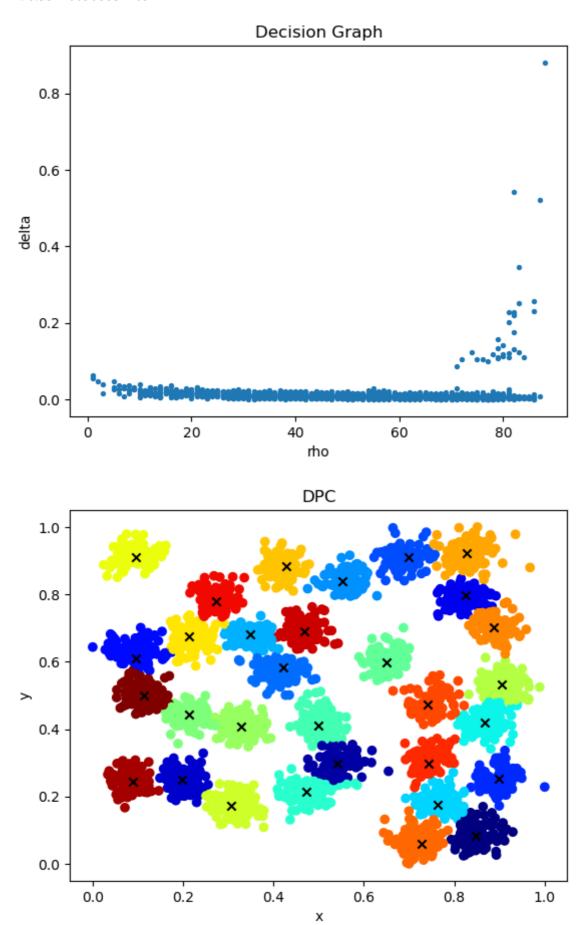
# Aggregation.txt数据集

参数 dc = 0.1, rho\_bound = 30, delta\_bound = 0.115

DBI: 0.5461285787085287



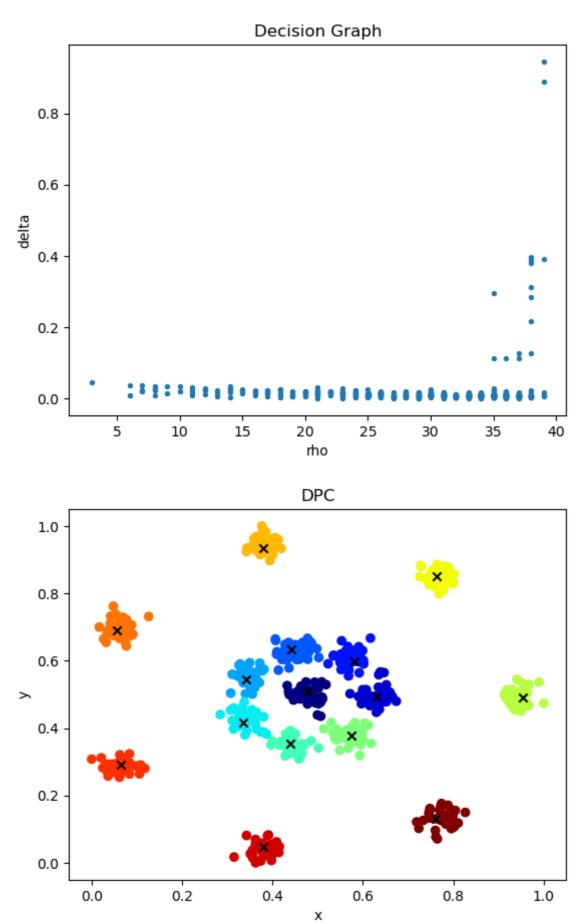
DBI: 0.5521069688311097



## R15.txt数据集

参数 dc = 0.05, rho\_bound = 30, delta\_bound = 0.08

DBI: 0.31471445116423397



### 和K-means比较

	DPC	K-means
Aggregation	0.5461285787085287	0.7050277591438034
D31	0.5521069688311097	0.5470674995427992
R15	0.31471445116423397	0.31471445116423397

可以看出,DPC在一些特定的数据集上表现明显好于K-means算法,比如Aggression中,样本点分布的并不均匀且形成的聚类不是圆。在D31和R15上这两个算法的表现则相近

# 实验结果分析

DPC算法整合了k-means 算法和DBSCAN算法,可以处理非圆形(球形)的簇以及重叠度高的簇,通过选取合适的参数可以达到非常好的效果,比传统的聚类算法更加优越